Triton入门级教程

整体架构：

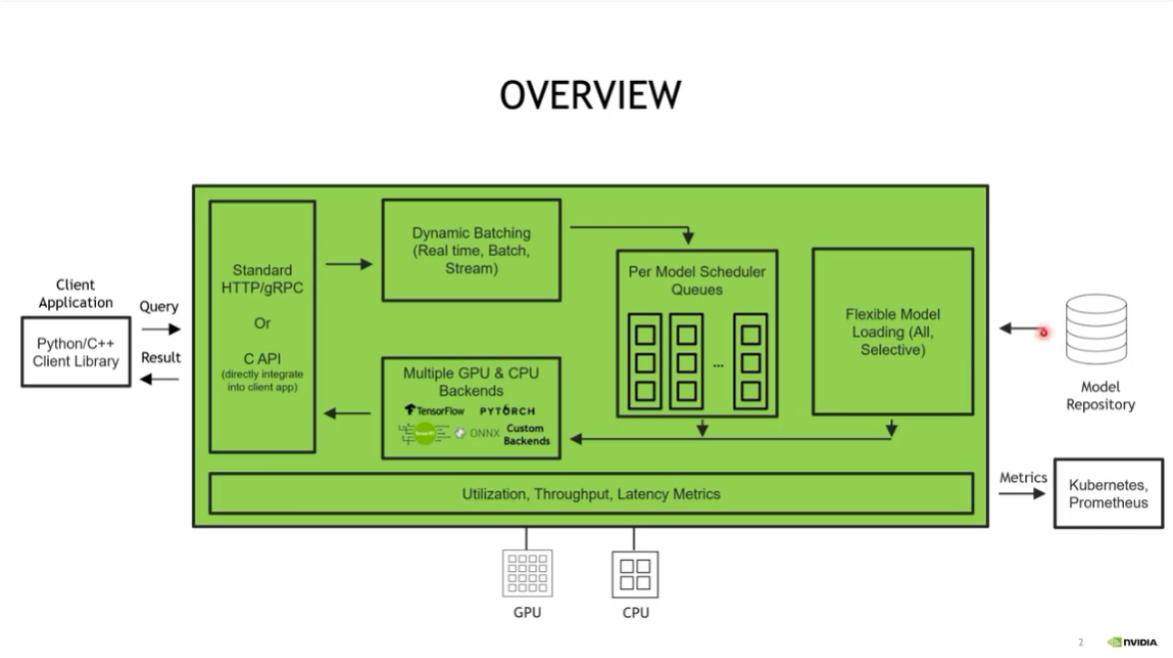

1、Prepare the Model Repository

三级结构：

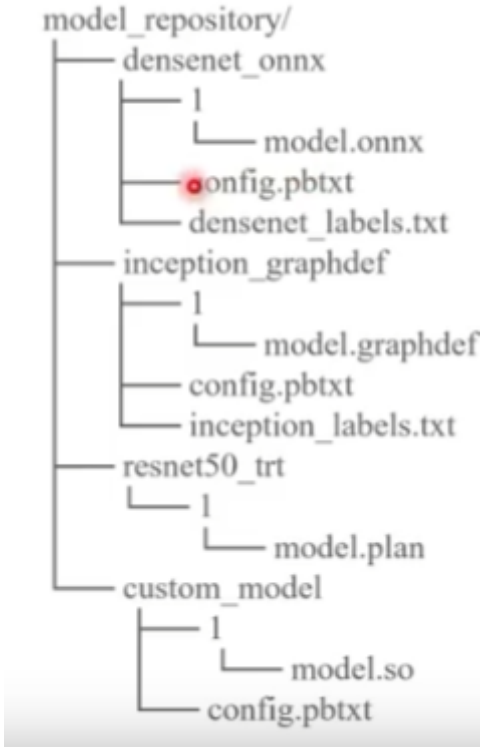

- Model Repository目录
  - 具体某一个推理模型目录：装配所有的模型

- 版本目录：模型文件
- config文件
- label files

1.1 model files

模型目录重要的Components：

- TensorRT: model.plan
- ONNX: model.onnx
- TorchScriptss: model.pt
- TensorFlow: model.graphdef, or model.savemodel /
- Python: model.py
- DALI: model.dali
- OpenVINO: model.xml and model.bin
- Custom: model.so

通过版本号找到正确版本的模型

1.2 Config File

定义模型和服务器的配置参数

1.3 Label File

对于分类模型，label file自动产生类别名的预测概率，方便我们读取分类模型的输出

2、Configure the Served Model

2.1 必须包含的信息

config.pbtxt文件中必须包含的信息

- 指定模型跑在哪个backend上面：platform / backend
- max_batch_size：定义了模型最大能够执行的推理的batch是多少，用于限制模型推理不超过GPU的显存
- 输入和输出：Tensor

注意：在TensorRT, TensorFlow saved-model, ONNX models中config文件不是必须的，--strict-model-config=false。

	TensorRT	ONNX RT	TensorFlow	PyTorch	OpenVINO	Python	DALI	Custom
platform	tensorrt_plan	onnxruntime_onnx	tensorflow_graphdef or tensorflow_savedmodel	pytorch_libtorch	/	/	/	~~custom~~
backend	tensorrt	onnxruntime	tensorflow	pytorch	openvino	python	dali	<backend_name>

Optionally choose 1 from 2
Must be set
Optional
Must not be set

绿色的二者选其一，红色是必须指定。

max_batch_size & input & output: (-1代表可变长度)，max_batch_size=0表示模型的dims必须是真实的dims。

2.2 Version Policy

三个策略指定版本的信息：

2.3 Instance Groups

同时跑多个Instance提高GPU利用率

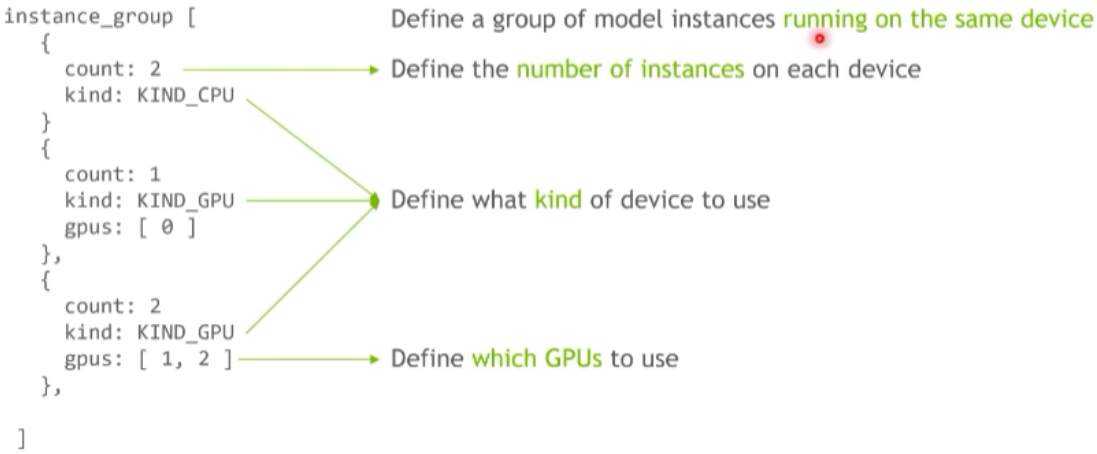

2.4 调度策略

Default Scheduler:

- no batching
- 发送请求是多少就是多少batch_size

Dynamic Batcher：最重要提升吞吐性能，提升GPU利用率

- preferred_batch_size：期望达到的batch_size
- max_queue_delay_microseconds：100：打batch的时间限制，越大表示愿意等待更多的请求

使用Dynamic Batcher之后客户端将比较小的请求合并成比较大的请求，可以极大提升模型的吞吐。

Sequence Batcher:

```
sequence_batching {
max_sequence_idle_microseconds:5000000
  control_input [
    {
      name: "START"
      control [
        {
          kind: CONTROL_SEQUENCE_START
          int32_false_true: [ 0, 1 ]
        }
      ]
    },
    {
      name: "READY"
      control [
        {
          kind: CONTROL_SEQUENCE_READY
          int32_false_true: [ 0, 1 ]
        }
      ]
    },
    {
      name: "END"
      control [
        {
          kind: CONTROL_SEQUENCE_END
          int32_false_true: [ 0, 1 ]
        }
      ]
    },
    {
      name: "CORRID"
      control [
        {
          kind: CONTROL_SEQUENCE_CORRID
        data_type: TYPE_UINT64
        }
      ]
    }
  ]
oldest {
max_candidate_sequences:2200
preferred_batch_size:[256,512]
max_queue_delay_microseconds:1000
}
}
```

Ensemble Scheduler: 组合成pipeline

2.5 优化手段

针对ONNX模型，可以直接开启TensorRT加速，TRT backend for ONNX

```
optimization { execution_accelerators {
  gpu_execution_accelerator : [ {
    name : "tensorrt"
    parameters { key: "precision_mode" value: "FP16"
}
    parameters { key: "max_workspace_size_bytes"
value: "1073741824" }
    }]
}}
```

2.6 Model Warmup

热身的过程使模型推理稳定，热身完之后模型被加载进来并提供服务，但是模型加载比较漫长

```
model_warmup [
  {
    batch_size: 64
    name: "warmup_requests"
    inputs {
      key: "input"
      value: {
        random_data: true
        dims: [ 299, 299, 3]
        data_type: TYPE_FP32
      }
    }
  }
]
```

3、Launch Triton Server

tritonserver --help：查看tritonserver所有的options

检查Server健康状态：curl -v <Server IP>:8000/v2/health/ready

3.1 常用选项

--log-verbose <integer>

--strict-model-config <boolean>

--strict-readiness <boolean>：检查健康状态什么情况下显示ready

--exit-on-error <boolean>：如果为true，所有模型必须load成功，否则模型开启不起来

--http(grpc, metrics)-port <integer>：使用端口

--model-control-mode <string>：以什么模式管理模型库，Options包含"none", "poll"（动态更新）, "explicit"（在server启动初期是不加载模型的） --load-model resnet_50.onnx，在初期加载模型。curl -X POST http://localhost:8000/v2/repository/models/resnet50_pytorch/load （load换成unload就是卸载模型）

--pinned-memory-pool-byte-size <integer>：模型推理有效提高CPU/GPU数据传输效率，256M

--cuda-memory-pool-byte-size <integer>：可以访问的CUDA memory的大小，64M

--backend-directory：找backend编译的动态库

--repoagnet-directory：用于预处理模型库的程序（加密）

4、Configure an Ensemble Model

子模块需要准备好，放在model_repository里面，创建ensemble model，在语音识别模型中对应着attention_rescoring

```
name: "attention_rescoring"
platform: "ensemble"
max_batch_size: 64 #MAX_BATCH

input [
  {
    name: "WAV"
    data_type: TYPE_FP32
    dims: [-1]
  },
  {
    name: "WAV_LENS"
    data_type: TYPE_INT32
    dims: [1]
  }
]

output [
  {
    name: "TRANSCRIPTS"
    data_type: TYPE_STRING
    dims: [1]
  }
]
```

定义模块之间的连接关系

key：input_tensor和output_tensor在模型文件本身定义的名字

value：input_tensor和output_tensor在ensemble模型里面定义的名字，用于连接不同的step

可以服务于Stateful model，不是实际的模型，只是一种调度策略，每一个子模块有各自的调度器，模块之间的数据传输通过CPU memory。每一个子模型model instance是解耦的。

Feature extractor模块

```
ensemble_scheduling {
step [
{
    model_name: "feature_extractor"
    model_version: -1
    input_map {
    key: "wav"
    value: "WAV"
}
input_map {
    key: "wav_lens"
    value: "WAV_LENS"
}
output_map {
    key: "speech"
```

```
    value: "SPEECH"
}
output_map {
    key: "speech_lengths"
    value: "SPEECH_LENGTHS"
}
},
```

Encoder模块

```
{
    model_name: "encoder"
    model_version: -1
    input_map {
    key: "speech"
    value: "SPEECH"
}
input_map {
    key: "speech_lengths"
    value: "SPEECH_LENGTHS"
}
output_map {
    key: "encoder_out"
    value: "encoder_out"
}
output_map {
    key: "encoder_out_lens"
    value: "encoder_out_lens"
}
output_map {
    key: "beam_log_probs"
    value: "beam_log_probs"
}
output_map {
    key: "beam_log_probs_idx"
    value: "beam_log_probs_idx"
}
},
```

scoring模块

```
{
    model_name: "scoring"
    model_version: -1
    input_map {
    key: "encoder_out"
    value: "encoder_out"
}
input_map {
    key: "encoder_out_lens"
    value: "encoder_out_lens"
}
input_map {
    key: "batch_log_probs"
    value: "beam_log_probs"
}
```

```
input_map {
    key: "batch_log_probs_idx"
    value: "beam_log_probs_idx"
}
output_map {
    key: "OUTPUT0"
    value: "TRANSCRIPTS"
}
}
```

5、Send Requests to Triton Server

```
import tritonclient.grpc as grpcclient
```

1. 创建client对象：grpcclient.
2. 获取config数据：tritonclient.get_model_metadata
3. 准备输入原始数据
4. 打包到request里面，准备好inputs对象和outputs对象
5. 发送请求执行推理：异步、同步、streaming

当在同一台机器部署server client时，使用shared memory模块，python_backend使用shared memory传输数据。